

GMP 환경에서의 AI 활용

김화종 | K-MELLODDY 사업단장

강사소개

- **한국제약바이오협회 K-MELLODDY 사업단장**
 - 연합학습 기반 신약개발 가속화 프로젝트 사업단 (복지부·과기부 공동)
- **한국제약바이오협회 AI신약융합연구원장 / AI신약개발지원센터장**
- **PDA Korea Chapter 부회장**
- **KAIST IT융합연구소 겸직교수**
- **강원대학교 컴퓨터공학과 교수 / 강원대학교병원 겸직교수**
- **강의**
 - 데이터사이언스 · 파이썬 · 머신러닝 · AI부트캠프
 - LG전자, LS그룹, 한전, 두산, KB금융, 동아, 셀트리온

목차

- **Part 1 | GMP에 왜 AI가 필요한가**
 - 현장의 문제 · 규제 진화 · Data Integrity to Data Value
- **Part 2 | GMP의 어떤 영역에 AI를 도입하는가**
 - 주요 적용 영역 · QbD · 규제 친화적 AI · GAIP
- **Part 3 | AI는 어떻게 동작하고 구현하는가**
 - ML/DL 알고리즘 · 실습 환경
- **Part 4 | 실습 예제**
 - EDA · SPC · OOS · 이상탐지 · Deviation · CAPA · CNN · LSTM · 소프트센서 · RTRT

GMP에 왜 AI가 필요한가

PART 1

현장의 문제

- ① 문서 작성 부담
 - Deviation 1건에 보고서·CAPA·SOP 개정까지 수십 장의 문서를 사람이 직접 작성
- ② OOS·이탈 사후 대응
 - 이미 발생한 OOS를 뒤늦게 발견 — 원인 추적과 재발 방지에 막대한 시간 소모
- ③ 데이터는 쌓이는데 활용하지 못 함
 - LIMS·DCS·MES에 데이터는 넘치지만 의사결정에 연결되지 못하는 정보의 낭비
- ④ 규제 대응 과부하
 - FDA·EMA 실사 준비에 전문 인력이 수개월 투입 — 반복 작업에 혁신 역량 낭비

이러한 문제의 공통점: 반복적이고, 데이터가 있고, AI로 개선할 수 있다

Data Integrity

- **ALCOA+ 원칙 (FDA 요구사항)**
 - Attributable — 누가 언제 생성했는지 추적 가능
 - Legible — 가독성 있고 영구 보존
 - Contemporaneous — 실시간 기록
 - Original — 원본 데이터 보존
 - Accurate — 정확성 검증 + Complete·Consistent·Enduring·Available
- **GMP에서 Data Integrity 위반 사례**
 - 데이터 사후 수정·삭제 → FDA 483 발행 → 생산 중단
 - Audit Trail 미비 → 21 CFR 211.192 위반
 - 수기 기록 오류·분실 → 배치 릴리즈 지연
- **AI가 Data Integrity를 강화하는 방법**
 - Audit Trail 자동 분석 → 이상 패턴 실시간 탐지
 - RAG 기반 SOP 검색 → 최신 규정 자동 연결

QbD의 AI 전환 (QbD → AX)

- **QbD (Quality by Design) 철학**
 - 품질은 검사로 확인하는 것이 아니라 설계 단계에서 구축한다
 - CPP (Critical Process Parameters) ↔ CQA (Critical Quality Attributes) 관계 규명
- **AI가 QbD 실행을 지원하는 방법**
 - 데이터 수집 (CPP, CQA) → AI 모델 → 품질 예측 + 공정 조정 권고
 - 비선형 CPP↔CQA 관계를 랜덤포레스트·딥러닝으로 정밀 모델링
 - 위험 기반 공정 조정 의사결정 보조
- **AX (AI Transformation) Process 흐름**
 - 데이터 수집 → 전처리 (스케일링·이상치 처리) → AI 모델 학습
 - 품질 예측 / 핵심 변수 분석 / 제어변수 조정 권고
 - 온도·pH·교반속도 등 CPP 최적화 → 불량 방지·수율 개선

규제 친화적(Trustworthy) AI

일반적 AI

- 최고 성능 모델 추구
- 블랙박스 모델 한계
- 데이터 출처·버전 관리 미흡
- 감사 대응 한계

규제 친화적 AI

- ✓ 불확실성 정량화 (예: confidence score)
- ✓ 추적 가능성(Data + Model lineage)
- ✓ 재현성·검증 가능성 내장
- ✓ 운영 중 성능 저하 모니터링

Human Oversight 원칙: AI는 판단을 보조하고, 최종 품질 판단과 승인은 책임 있는 GMP 담당자가 수행한다

규제기관의 핵심 질문: 이 AI의 COU(Context of Use)는 무엇인가? 어떤 데이터로 개발·검증했는가? 위험도는 어느 수준인가? 운영 중 성능 저하와 변경관리는 어떻게 수행하는가?

데이터는 규제 대상인가, 경쟁 자산인가?

Compliance Era

- 데이터는 규제 의무 · 감사용 증빙
- 수기 기록 관리
- 사후 대응 (Reactive)
- 비용 발생 요인으로 인식
- 부서간/기기간 데이터 분절

AX Era

- 데이터는 전략 자산 · 인사이트 원천
- AI로 자동 분석·실시간 처리
- 사전 예측 (Proactive)
- 비즈니스 경쟁력 핵심 자원
- 효율적인 통합 데이터 관리 가능

GMP의 어떤 영역에 AI를 도입하는가

PART 2

GMP AI 적용 주요 영역

- ① **품질관리 (QC/QA) 영역**
 - OOS 사전 예측, 배치 합격 확률, 통계적 공정관리(SPC) 자동화
- ② **공정 모니터링 영역**
 - 실시간 이상 탐지, 공정 드리프트 감지, 소프트웨어 구현
- ③ **편차/CAPA 관리 영역**
 - Deviation 자동 분류, CAPA 효과성 예측, 근본원인 추천
- ④ **설비 유지보수 영역**
 - 잔여 수명(RUL) 예측, 예지보수 스케줄 최적화
- ⑤ **실시간 방출 시험 (RTRT) 영역**
 - 소프트웨어 기반 CPP→CQA 예측, FDA PAT 기반 인라인 품질 판정

① 품질관리 영역 — OOS 예측과 SPC

- **전통적 SPC의 한계**
 - Shewhart 관리도: $\pm 3\sigma$ 기준, 갑작스러운 큰 이탈만 감지
 - CUSUM: 누적 편차로 소규모 지속 드리프트 감지 (보완적)
 - 규칙 기반이므로 복잡한 다변량 공정에서 한계
- **AI 기반 OOS 예측의 장점**
 - 다변량 입력(온도, pH, 압력, 교반속도 등) 동시 학습
 - 비선형 관계 포착 → 기존 SPC가 놓치는 패턴 감지
 - OOS 발생 전 미리 경고 → 배치 구제 가능성 증가
- **예제3 — OOS 예측 모델 (랜덤포레스트)**

② 공정 모니터링 — 이상탐지와 패턴인식

- **이상탐지 (Anomaly Detection)**
 - 정상 공정 데이터만으로 학습 → 이상 점수(anomaly score) 산출
 - Isolation Forest: 고차원 공정 데이터에 효과적, 레이블 불필요
 - 예제4: 비지도 학습 기반 공정 이상탐지
- **패턴인식 (Pattern Recognition)**
 - 시계열 공정 데이터에서 비정상 패턴 자동 분류
 - Conv1D CNN: 1D 합성곱 신경망으로 시계열 특징 추출
 - 예제7: 공정 상태 5클래스 분류 (정상/과온/저온 등)
- **소프트센서 (Soft Sensor)**
 - 직접 측정 어려운 품질 변수를 CPP로 실시간 예측
 - 예제10: 페니실린 농도 실시간 예측

③ Deviation/CAPA 관리 — 분류와 효과성 예측

- **Deviation 자동 분류**
 - K-Means 군집화: 유사 Deviation 자동 그룹핑
 - 과거 Deviation 패턴에서 근본원인 카테고리 자동 식별
 - 예제5: K-Means 기반 Deviation 분류
- **CAPA 효과성 예측**
 - 과거 CAPA 데이터 학습 → 신규 CAPA 성공 확률 예측
 - 재발 방지 우선순위 결정 지원
 - 예제6: 랜덤포레스트 기반 CAPA 효과성 분류
- **LLM 활용 가능성 (미래 방향)**
 - Deviation 보고서 초안 자동 생성 (RAG + GPT)
 - 규제 문서 자동 연결 및 SOP 참조

④ 예지보수 — 잔여 수명(RUL) 예측

- **예지보수의 GMP 중요성**
 - 동결건조기 고장 → 배치 손실 + FDA 규정 위반 위험
 - 사후보수(Reactive) → 계획보수(Preventive) → 예지보수(Predictive)
- **LSTM 기반 RUL 예측**
 - LSTM (Long Short-Term Memory): 장기 시계열 의존성 학습
 - 센서 데이터(진동, 온도, 압력)로 고장까지 남은 시간 예측
 - 예측 결과 기반 최적 교체 시점 결정
 - 예제8: 동결건조기 RUL 예측
- **GMP 적용 시 고려사항**
 - 예측 불확실성 구간 제공 (Trustworthy AI 요구사항)
 - 센서 캘리브레이션 이력 관리
 - 유지보수 의사결정은 최종적으로 인간이 수행

⑤ 실시간 방출 시험 (RTRT)

- **RTRT (Real-Time Release Testing) 개념**
 - FDA PAT Guidance (2004): 공정 중 수집된 데이터로 최종 품질 판정
 - 배치 완료 후 시험 → 공정 중 연속 예측으로 전환
 - 조건: 예측 모델의 $R^2 \geq 0.80$ (신뢰성 임계값)
- **소프트센서 기반 RTRT 구현**
 - CPP (T, pH, DO₂, 기류, 기질 농도) → 품질 속성 (P:g/L) 예측
 - 진행률별 배치 데이터로 RTRT 적용 가능 시점 탐색
 - 60~70% 진행 시점부터 $R^2 \geq 0.80$ 달성 가능
- **페니실린 발효 사례 (IndPenSim V3 데이터셋)**
 - 100,000L 발효조, 100 배치, 33개 공정 변수
 - 예제9 (EDA) + 예제10 (소프트센서 + RTRT 타이밍 분석)

AI는 어떻게 동작하고 구현하는가

PART 3


AI 동작 원리

데이터(x) → 모델(AI) → 가치(y)

수식, 논리로 설명하기 어려운 복잡한 실세계 문제를, 데이터로부터 학습한 모델로 해결한다


예측	추천	최적화	이상탐지	생성
Prediction $X \rightarrow \text{Model} \rightarrow y$	Recommendation $X \rightarrow \text{Model} \rightarrow \text{candidate}$	Optimization $X \rightarrow \text{Model} \rightarrow \text{control}$	Anomaly Detection $X \rightarrow \text{Model} \rightarrow y$	Generation $X \rightarrow \text{Model} \rightarrow X'$
제조: OOS·배치 품질 예측 신약: 독성·ADMET·PK 예측	제조: CAPA 후보, 원인분석 추천 임상: 시험 프로토콜 조건 추천	제조: CPP 조정, 수율·순도 최적화 임상: 용량·투여일정 최적화	제조: audit trail 이상, 공정 drift 임상: 부작용 신호 탐지 (PV)	GMP: SOP·Deviation 보고서 규제: CTD·IB 문서 생성, 검토

AI 구현 체계



AI 모델

- 데이터 전처리
 - AI 모델이 인식 가능하도록 입력을 적절한 수치로 변환 하는 것
- 훈련데이터로 모델을 학습시키고 검증 데이터로 동작 확인



데이터 전처리

- 데이터 정제 (cleaning)
 - 빠진 값을 처리하거나 오류를 수정하는 것
- 이상치 처리
 - 비정상적으로 튀는 값(이상치)을 찾거나 제거하는 것
- 데이터 변환 (transformation)
 - 로그, 역수, 승수, 카테고리 변수를 적용하는 것
- 스케일링 (scaling)
 - 여러 데이터의 특성 값의 범위를 동일한 조건으로 조정하는 것
- 특성 선택과 차원 축소
 - 특성 중 일부를 선택하거나 특성을 조합하여 새로운 특성을 만드는 것
 - 주성분 분석(PCA): 머신러닝에 사용할 특성의 수를 줄이는 것
 - Principal components analysis

데이터 전처리 — GMP 데이터의 특성


- **GMP 데이터의 공통 문제**
 - 결측치: 센서 오류, 설비 중단, 이상 배치 → fillna, interpolate, dropna
 - 이상치: 캘리브레이션 오류, 수기 입력 오류 → IQR, Z-score 필터링
 - 클래스 불균형: 불량 배치 < 5% → SMOTE, class_weight 조정
- **스케일링 (Scaling)**
 - StandardScaler: $(x-\mu)/\sigma$ → 정규분포 가정, RF에도 효과적
 - MinMaxScaler: $(x-\min)/(\max-\min)$ → 신경망 학습에 적합
 - 주의: Test set은 Train set 통계로 변환 (데이터 누수 방지)
- **시계열 데이터 분할 주의사항**
 - 랜덤 분할 금지 → 시간 순서 유지, 배치 단위 분할
 - 배치 분할: train_batches=[1..70], test_batches=[71..90]

머신러닝 유형

머신러닝 유형		알고리즘	특징
지도학습 (y가 존재)	선형 계열	선형 모델, SVM, 로지스틱회귀	곱셈과 덧셈으로 점수를 구하고 이를 이용하여 회귀와 분류 예측
	신경망	MLP, CNN, RNN, Transformer Graph Network	매트릭스 연산을 기반으로 점수를 계산하며 활성화 함수 도입
	트리 계열	결정 트리, 랜덤포레스트, 부스팅	True/False 선택을 반복하여 회귀와 분류 예측 수행. 스케일링이 필요없다
	기타	kNN, 베이즈	특성 공간상의 거리를 기준, 또는 조건부 확률을 기준으로 예측
비지도학습 (y가 없음)	클러스터링	k-means, DBSCAN	특성 공간상 거리 또는 유사도를 기준으로 샘플을 그룹핑
	데이터 변환	스케일링, 로그 변환, 카테고리 인코딩	모델의 성능을 높이 위한 데이터 전처리
	차원 축소	PCA, t-SNE	계산량을 줄이고 모델 성능을 향상, 또는 시각화를 위한 차원 축소
	표현 학습	LLM 등 파운데이션 모델	입력 데이터를 latent vector로 표현하는 비지도 학습
강화학습		시행착오의 경험을 누적	샘플 입력마다 정답이 있지 않지만 최종적으로 달성해야 할 목표를 알려주고 보상을 통해 학습

랜덤 포레스트

- 훈련 데이터의 일부만 사용하거나 특성의 일부만 무작위로 선택한 간단한 구조의 결정 트리(weak learner)를 수백개 만들고 이 결과의 평균치를 사용하는 방법 - 앙상블(ensemble) 방법



모델 성능 평가 지표

- **회귀 (Regression) 지표 — 품질 수치 예측 시**
 - R^2 (결정계수): 1.0 = 완벽 예측 / 0.0 = 평균 예측 수준 / <0 = 최악
 - RMSE: 예측 오차의 평균 크기 (단위 동일, 작을수록 좋음)
 - MAE: 예측 오차의 절댓값 평균 (이상치에 덜 민감)
- **분류 (Classification) 지표 — OOS 여부 예측 시**
 - Accuracy: 전체 정확률 (클래스 불균형 시 오해 가능)
 - F1-Score: Precision·Recall 조화평균 (불균형 데이터에 적합)
 - ROC-AUC: 임계값 변화에 따른 TPR vs FPR 곡선 면적
- **과적합 vs 과소적합**
 - Train $R^2 \gg$ Test R^2 : 과대적합 → 일반화, 트리 깊이 제한, 교차검증, 데이터 추가
 - Train $R^2 \approx$ Test R^2 낮은 값: 과소적합 → 모델 복잡도 증가, 특성 추가


혼동행렬 (Confusion Matrix)

- 분류 모델의 성능을 4개 구역으로 표현
 - TP (True Positive): OOS 예측 → 실제 OOS ✓ (올바른 경보)
 - TN (True Negative): 정상 예측 → 실제 정상 ✓ (올바른 통과)
 - FP (False Positive): OOS 예측 → 실제 정상 ✗ (불필요한 경보)
 - FN (False Negative): 정상 예측 → 실제 OOS ✗ (놓친 불량)
- 분류 성능 지표
 - Recall (재현율) = $TP / (TP+FN)$: FN 최소화 → 불량 놓침 방지
 - Precision (정밀도) = $TP / (TP+FP)$: FP 최소화 → 불필요한 폐기 방지
 - F1-Score = $2 \times Precision \times Recall / (Precision+Recall)$ - 조화평균

		예측		
		Positive	Negative	
실제	Positive	6	4	Recall=6/10
	Negative	3	87	
		Precision=6/9		


Accuracy (정확도): 93/100
Precision: 6/9
Recall (Sensitivity): 6/10

ROC 그래프




AUC(Area Under Curve)

- ROC 그래프의 면적을 계산
- 우수한 알고리즘일수록 초반에 y축 상단 방향으로 이동하므로 ROC 커브의 면적이 넓어짐




MLP (Multi-Layer Perceptron)

- 히든 계층이 6개인 예 (MLP는 2개 층만 사용해도 기본 동작은 한다)




CNN (Convolution Neural Network)



딥러닝: Conv1D CNN — 시계열 패턴인식

- **Conv1D (1차원 합성곱 신경망) 개념**
 - 이미지의 Conv2D를 시계열 데이터에 적용
 - 슬라이딩 윈도우로 지역 패턴(피크, 드리프트) 자동 추출
 - 패턴 인식에 효과적
- **GMP 공정상태 분류 (예제7)**
 - 입력: 시계열 센서 데이터 (window_size=50, n_features=6)
 - 출력: 공정 상태 클래스 분류
- **GMP 실습 코드 (예제7)**
 - `from tensorflow.keras.layers import Conv1D, MaxPooling1D, Flatten`
 - `model.add(Conv1D(64, kernel_size=3, activation='relu'))`
 - `model.add(MaxPooling1D(pool_size=2))`
 - `model.add(Flatten())`
 - `model.add(Dense(5, activation='softmax')) # 5클래스 분류`

RNN (Recurrent Neural Network)



- 위 표현에서 활성화 함수와 bias는 생략됨
- 상태값 h 를 다음 스텝에 사용한다
- U, V, W 는 i 의 함수가 아니라 모든 스텝에서 같은 모양을 갖는다

딥러닝: LSTM — 시계열 데이터 학습


- **LSTM (Long Short-Term Memory) 개념**
 - RNN의 장기 의존성 문제(기울기 소실)를 게이트 구조로 해결
 - Forget Gate / Input Gate / Output Gate로 장기 기억 조절
- **GMP 적용 장점**
 - 공정 시계열 (온도·pH·진동)의 장기 패턴 학습
 - 고장 징후(점진적 열화)를 멀리서부터 감지 가능
- **GMP 실습 코드 (예제8)**
 - `from tensorflow.keras.layers import LSTM, Dense`
 - `model.add(LSTM(64, return_sequences=True, input_shape=(T, F)))`
 - `model.add(LSTM(32))`
 - `model.add(Dense(1)) # RUL 예측 (회귀)`

비지도 학습: Isolation Forest — 이상탐지

- **작동 원리**
 - 랜덤 분할로 데이터 포인트를 고립시키는 트리 구성
 - 이상치 = 고립이 쉬운 (트리 깊이가 얕은) 데이터 포인트
 - 레이블(정상/이상 태그) 없이 학습 가능 → 비지도 학습
- **GMP 공정 이상탐지 장점**
 - 정상 공정 데이터만으로 기준 학습
 - 신규 공정에서도 이상 여부 즉시 판단 가능
 - 고차원 다변량 공정 데이터에서 강건하게 동작
- **GMP 실습 코드 (예제4)**
 - `from sklearn.ensemble import IsolationForest`
 - `iso = IsolationForest(contamination=0.05, random_state=42)`
 - `iso.fit(X_train)` # 정상 데이터로만 학습
 - `scores = iso.decision_function(X_test)` # 이상 점수


비지도 학습: K-Means — 군집화

- 작동 원리
 - K개의 중심(centroid)을 초기화 → 가장 가까운 중심에 할당 → 중심 재계산 반복
 - 수렴 후 K개의 군집(cluster)으로 데이터 분류
- 최적 K 선택 방법
 - Elbow Method: 군집 내 분산(Inertia) 감소율이 꺾이는 K 선택
 - Silhouette Score, Dendrogram 그래프 사용법
- GMP Deviation 분류 (예제5)
 - 입력: Deviation 텍스트 특성 벡터 (TF-IDF 또는 수치 속성)
 - 출력: 유사 Deviation 그룹 → 근본원인 카테고리 자동 식별



PCA

- PCA(Principal components analysis)
 - 기존의 특성들을 차원수가 적은 다른 특성들로 표현




PCA — 주성분 분석

- **PCA (Principal Component Analysis) 개념**
 - 고차원 데이터를 분산이 최대인 방향(주성분)으로 투영
 - 차원 축소 → 시각화, 노이즈 제거, 연산 효율화
- **GMP 활용 예시**
 - 30개 공정변수 → PC1, PC2로 축소 → 2D 공정 상태 시각화
 - 배치 간 품질 변동 원인 탐색 (Batch Score Plot)
 - 다중공선성 제거 후 모델 입력으로 활용
- **실습 코드**
 - `from sklearn.decomposition import PCA`
 - `pca = PCA(n_components=2) # 2차원으로 축소`
 - `X_2d = pca.fit_transform(X_scaled)`
 - `print(pca.explained_variance_ratio_) # 설명된 분산 비율`

GMP AI 실습 예제

PART 4

실습 환경



GMP AI 예제 모듈

- **모듈 ① GMP 데이터 탐색 및 공정 모니터링**
 - **예제1 품질데이터탐색 (EDA) · *예제2 SPC관리도
- **모듈 ② 예측적 품질관리**
 - **예제3 OOS예측모델 · **예제4 이상탐지
- **모듈 ③ QMS 자동화 지원**
 - *예제5 Deviation분류 · 예제6 CAPA효과성평가
- **모듈 ④ 딥러닝 공정 모니터링**
 - 예제7 공정상태패턴인식(Conv1D) · *예제8 예지보수(LSTM)

예제1 — 품질 데이터 탐색 (EDA)

- **GMP 커버리지**
 - 21 CFR 211.192 배치 기록 검토, ICH Q8 공정 이해
- **학습 목표**
 - Pandas EDA: describe(), 분포, 상관관계 히트맵, 이상치 박스플롯
- **핵심 내용**
 - 합성 의약품 품질 데이터 (순도, 함량, 용해도 등) 탐색
 - 히트맵으로 CPP-CQA 상관관계 확인 → 주요 공정변수 식별
 - 배치별 품질 트렌드 시각화 → 품질 변동 원인 가설 수립
- **AI 도입 장점**
 - 수백 배치의 패턴을 자동 탐색 → 수작업 검토 대비 10배 이상 속도
- **Takeaway**
 - EDA는 AI 모델링 이전 필수 단계 — 데이터를 먼저 이해해야 모델이 의미 있다

예제2 — SPC 관리도 (Shewhart & CUSUM)

- **GMP 커버리지**
 - ICH Q10 지속적 공정 검증, 21 CFR 211.192 공정 일탈 관리
- **학습 목표**
 - Shewhart 3σ 관리도, CUSUM 관리도 직접 구현 및 비교
- **핵심 내용**
 - Shewhart: $UCL/LCL = \mu \pm 3\sigma \rightarrow$ 갑작스러운 큰 이탈 감지
 - CUSUM: $S_t = \max(0, S_{t-1} + (x_t - \mu) - k) \rightarrow$ 소규모 지속 드리프트 감지
 - 두 방법의 보완적 활용: Shewhart(갑작스러운 변화) + CUSUM(서서히 진행)
- **AI 도입 장점**
 - 다변량 공정에서 SPC를 넘어 ML 기반 이상탐지로 확장 가능
- **Takeaway**
 - SPC는 GMP 필수 도구 — CUSUM은 드리프트 감지에 Shewhart보다 우수

예제3 — OOS 예측 모델 (랜덤포레스트)

- **GMP 커버리지**
 - 21 CFR 211.192 OOS 조사, ICH Q9 위험 기반 관리
- **학습 목표**
 - 랜덤포레스트 분류 모델 구축, Feature Importance, 혼동행렬 해석
- **핵심 내용**
 - 입력(X): 온도, pH, 반응시간, 투입 농도 등 공정변수
 - 출력(y): OOS 여부 (0=합격, 1=불합격) — 배치 릴리즈 전 예측
 - Recall 우선 최적화 → 불량 놓침(FN) 최소화
 - Feature Importance로 가장 큰 영향 변수 식별 → QbD 연계
- **AI 도입 장점**
 - 배치 완료 전 OOS 경보 → 조기 개입으로 배치 손실 절감
- **Takeaway**
 - GMP에서는 Recall(불량 감지율)이 Precision보다 우선순위 높다

예제4 — 공정 이상탐지 (Isolation Forest)

- **GMP 커버리지**
 - FDA PAT 연속 공정 모니터링, ICH Q9 위험 식별
- **학습 목표**
 - 비지도 학습으로 이상 탐지, anomaly score 시각화, PCA 2D 투영
- **핵심 내용**
 - 정상 공정 데이터(Fault=0)로만 학습 → 이상 패턴 자동 탐지
 - contamination=0.05: 전체의 5%를 이상치로 가정
 - PCA 2차원 투영으로 정상/이상 클러스터 시각화
 - 이상 배치 → 공정 파라미터 추적 → 근본원인 파악 지원
- **AI 도입 장점**
 - 레이블 없이 신규 이상 패턴 탐지 가능 — 사람이 모르는 이상도 감지
- **Takeaway**
 - 비지도 이상탐지는 레이블 구축이 어려운 GMP 환경에 매우 적합

예제5 — Deviation 분류 (K-Means 군집화)

- **GMP 커버리지**
 - ICH Q10 CAPA 체계, EU GMP Annex 1 Deviation 관리
- **학습 목표**
 - K-Means 군집화, Elbow/Silhouette 최적 K, 군집 특성 해석
- **핵심 내용**
 - 수백 건의 Deviation 기록 → K-Means로 자동 그룹핑
 - 각 군집의 주요 속성 분석 → 근본원인 카테고리 명명
 - 빈발 Deviation 클러스터 우선 CAPA 집중 → 재발 방지 효율화
- **AI 도입 장점**
 - 수작업 분류 대비 시간 90% 절감, 사람이 놓친 패턴 자동 발견
- **Takeaway**
 - 군집 결과의 GMP 의미 해석이 핵심 — 데이터 과학자와 QA 전문가 협업 필수

예제6 — CAPA 효과성 예측 (랜덤포레스트)

- **GMP 커버리지**
 - ICH Q10 CAPA 효과성 검증, 21 CFR 211.192 재발 방지
- **학습 목표**
 - 분류 모델로 CAPA 성공 여부 예측, 클래스 불균형 처리
- **핵심 내용**
 - 입력: CAPA 유형, 구현 시간, 담당 부서, 근본원인 카테고리 등
 - 출력: CAPA 효과성 (0=재발, 1=성공) — 신규 CAPA 적용 전 예측
 - SMOTE 또는 `class_weight`로 불균형 처리 (성공 CAPA >> 재발)
 - 고위험 예측 CAPA에 우선 자원 배분 의사결정 지원
- **AI 도입 장점**
 - CAPA 완료 전 성공 가능성 예측 → 고위험 CAPA에 집중 지원
- **Takeaway**
 - CAPA 데이터 품질이 모델 성능 결정 — 구조화된 CAPA 기록 필수

예제7 — 공정상태 패턴인식 (Conv1D CNN)

- **GMP 커버리지**
 - FDA PAT 연속 공정 모니터링, EU GMP Annex 11 자동화 시스템
- **학습 목표**
 - Conv1D CNN 시계열 분류, 슬라이딩 윈도우, 다중 클래스 분류
- **핵심 내용**
 - 합성 공정 시계열 데이터 (온도, 압력, 유량 등 6개 센서)
 - 5클래스: 정상 / 과온 / 저온 / 고압 / 저압
 - Window size=50 → Conv1D(64, 3) → MaxPool → Dense(5, softmax)
 - 실시간 공정 모니터링 → 이상 상태 즉각 분류 및 경보
- **AI 도입 장점**
 - LSTM 대비 빠른 학습, 단거리 패턴(급격한 변화) 효과적 감지
- **Takeaway**
 - Conv1D는 시계열 데이터의 지역 패턴 추출에 탁월 — GMP 공정 모니터링에 최적

예제8 — 예지보수 (LSTM + RUL 예측)

- **GMP 커버리지**
 - GAMP 5 설비 검증, ICH Q10 지속적 개선, GMP Annex 1 청정실 설비
- **학습 목표**
 - LSTM 기반 잔여 수명(RUL) 예측, 시계열 회귀, 예측 불확실성
- **핵심 내용**
 - 동결건조기(Lyophilizer) 센서 데이터: 진동, 온도, 압력, 소음
 - RUL = 현재 사이클에서 고장까지 남은 사이클 수
 - LSTM 2층 → Dense 출력 → MSE 손실 → 학습 후 예측 불확실성 추정
 - 예측 $R^2 > 0.85$ 달성 시 RTRT 개념과 동일하게 예지보수 승인 가능
- **AI 도입 장점**
 - 계획 정지 최소화, 예상치 못한 고장 방지 → 배치 손실 절감
- **Takeaway**
 - 예지보수는 GMP에서 즉각 가치 창출 가능한 고ROI AI 적용 사례

*Thank
you*